

Mikhael Groschitz

Engenheiro de Dados | SQL Server • Azure • Databricks | Python • PySpark • Lakehouse (Delta) • ETL/ELT

Porto Alegre, RS • +55 51 99200-0475 • mgroschitz@gmail.com

linkedin.com/in/mikhaelgroschitz • github.com/Mikhael-Groschitz • mgroschitz.dev

RESUMO

Engenheiro de dados com foco em SQL Server, Azure e Databricks. Hoje sou responsável pela estrutura de dados de um CRM em produção no Grupo Facta — modelagem, views, índices, constraints e otimização das consultas críticas — e mantenho automações em Python que sustentam a rotina da operação. Fora do trabalho, construo pipelines de ponta a ponta em Azure (Data Factory, ADLS Gen2, Azure SQL) e em Spark com Delta Lake, todos abertos no GitHub. Certificado em Databricks Fundamentals.

COMPETÊNCIAS TÉCNICAS

Bancos de dados e SQL: SQL Server, T-SQL, Azure SQL Database, otimização de consultas (planos de execução, indexação), modelagem dimensional, SCD Tipo 2, CDC; PostgreSQL, MongoDB

Cloud e plataformas: Azure (ADLS Gen2, Data Factory, Azure SQL), Databricks, Bicep (IaC)

Processamento e orquestração: Apache Spark (PySpark), Spark Structured Streaming, Delta Lake, Airflow, Kafka, dbt

Arquitetura e modelagem: Data Warehouse, Lakehouse, arquitetura medalhão (bronze/silver/gold), pipelines de dados ETL/ELT

Linguagens: Python (PySpark, Pandas, NumPy), SQL, T-SQL

Qualidade e práticas: Data quality, pytest, Git/GitHub, GitHub Actions (CI), Docker

BI: Power BI

EXPERIÊNCIA

Analista de Dados Backend (atuação em Engenharia de Dados) • Credware Tecnologia (Grupo Facta) mar/2026 – atual

Stack: SQL Server, T-SQL, Python, Databricks

- Redesenhei a modelagem do CRM jurídico em SQL Server (40+ tabelas, ~120 views), reduzindo em ~35% o tempo das principais rotinas; implantação em produção com o time de DBA, sem rollback.
- Otimizei ~50 consultas T-SQL críticas (planos de execução, índices e reescrita): consultas de ~8s passaram a ~1,5s, com ~45% menos CPU nos horários de pico.
- Desenvolvi e mantenho ~15 automações em Python, com monitoramento e logs, que substituíram rotinas manuais do setor jurídico (economia estimada de 25 a 30 horas/mês).
- Mapeei ~10 sistemas e seus fluxos de dados, e participo das decisões de arquitetura e refatoração do CRM avaliando impacto sobre processos, dados e usuários.
- Faço a interface entre negócio, dados e desenvolvimento: 30+ demandas traduzidas em requisitos técnicos e ~25 regras de negócio documentadas.

Analista de Dados Júnior • Escritório Contábil Fiscal Escofi nov/2024 – mar/2026

Stack: SQL, PostgreSQL, Python (Pandas, NumPy), Power BI

- Otimizei ~30 consultas e scripts de extração em SQL e Python sobre bases de 1 a 5 milhões de linhas, reduzindo o tempo de preparação dos dados de ~3h para ~1h.
- Apliquei detecção de anomalias em contas de maior materialidade, gerando ~20 lançamentos atípicos por ciclo para revisão e reduzindo em ~35% o tempo de triagem na auditoria.
- Apoiei ~5 modelos preditivos de fluxo de caixa e rentabilidade (horizontes de 30 a 90 dias, avaliados com MAPE) e ~10 dashboards em Power BI para ~20 usuários, reduzindo o tempo dos relatórios gerenciais de ~2 dias para ~4 horas.

Analista de Suporte de TI • PAYER out/2023 – out/2024

- Análise de tickets para achar causas raiz de problemas recorrentes, com dashboards de métricas e insights levados ao time de desenvolvimento.

PROJETOS DE ENGENHARIA DE DADOS (GITHUB)

Pipeline ELT de preços da ANP — Azure • github.com/Mikhael-Groschitz/anp-fuel-prices-elt-azure

- Data Factory metadata-driven, ADLS Gen2, Azure SQL, T-SQL, Bicep e Power BI sobre 20 anos de preços (219 arquivos, 35,3 mi de linhas em estágio e 32,2 mi na fato) em DW dimensional. Carga histórica de ~3h (projeção inicial: 15h) após inlining de UDF, índice clusterizado e SCD2 set-based; 8 checks de qualidade com log.

CDC do SQL Server para Data Warehouse dimensional • github.com/Mikhael-Groschitz/sqlserver-cdc-to-dw

- CDC nativo alimentando um DW em T-SQL e Python: extração incremental por LSN com watermark na mesma transação, SCD Tipo 2 com índice único filtrado, exclusão lógica na fato para preservar auditoria, 5 checks de qualidade e testes em pytest.

Lakehouse de CNPJ — Spark, Airflow e Delta (local) · github.com/Mikhael-Groschitz/cnpj-lakehouse-spark-airflow

- Airflow, PySpark, Delta Lake, MinIO e DuckDB em Docker sobre ~30 milhões de estabelecimentos da Receita Federal, de bronze a gold em ~2h40. Particionamento por UF reduziu 5.631 arquivos para 103; 99,99999% dos CNPJs validados e 30 cenários em pytest.

Streaming de propostas de crédito — Kafka, Spark e Delta (local) · github.com/Mikhael-Groschitz/credit-proposals-streaming-mongodb-kafka

- MongoDB change streams → Kafka → Spark Structured Streaming → Delta (bronze/silver/gold), com resume token e reconciliação Mongo × gold. Os checks de qualidade detectaram 508 transições inválidas, reduzidas a 2 casos residuais; um broadcast join removeu o gargalo de escala.

Expectativa vs. Realizado — Banco Central (Python e dbt) · github.com/Mikhael-Groschitz/bcb-macro-elt-python-dbt

- Ingestão idempotente das APIs SGS e Focus com watermark e lookback de 90 dias (~166 mil expectativas), snapshot SCD Tipo 2 e mart de erro de projeção em dbt; 65 testes Python, 69 testes dbt e CI no GitHub Actions.

Observabilidade de dados multi-backend · github.com/Mikhael-Groschitz/data-observability-multi-backend

- Serviço que monitora tabelas de outros pipelines (DuckDB e Postgres): frescor, nulos e schema calculados dentro do banco (1 linha trafegada mesmo em tabela de 500 mil linhas), contratos em YAML, baseline por mediana móvel e alertas por webhook; 114 testes.

FORMAÇÃO E CERTIFICAÇÕES

Pós-graduação em Arquitetura de Software, Ciência de Dados e Cybersecurity · PUCPR ago/2025 – out/2026 (previsto)

Tecnólogo em Análise e Desenvolvimento de Sistemas · Anhanguera jan/2023 – jun/2025

Databricks Academy Accreditation — Databricks Fundamentals · Databricks set/2026

Idiomas: Português (nativo) · Inglês (profissional completo) · Espanhol (uso profissional limitado)